WEB MINING

WEEK 10: DATASET, KARAKTERISTIK DATA, BOD DAN ALGORITMA

ANALISIS SENTIMEN BERBASIS ASPEK ULASAN GOOGLE PLAY SATUSEHAT MOBILE



Dosen Pengampu:
Ir. Devi Dwi Purwanto, S.Kom., M.Kom., CQAI., IPM.

ANGGOTA TIM

Bambang Herlambang	5803024019
Efraim Melvyn Rafelino Lahai	5803024009
Jap Robertus Kurniawan Setiabudi	5803024004
Robertus Geraldyn Alexandro Gabeler	5803024025

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS KATOLIK WIDYA MANDALA

SURABAYA

2026

Dataset, BOD, dan algoritma

Laporan week 10: sumber data, karakteristik, tujuan penelitian, serta rancangan analisis. Disusun berdasarkan dokumentasi proyek pada commit 3355814.

Topik penelitian

Analisis Sentimen Berbasis Aspek pada Ulasan Google Play SATUSEHAT Mobile: Perbandingan Label Manual dan Label LLM serta Pelacakan Sentimen Aspek per Versi Aplikasi.

Masalah yang dikaji

Satu ulasan dapat memuji tampilan, tetapi mengeluhkan login atau performa. Analisis per aspek diperlukan untuk memisahkan penilaian pada bagian aplikasi yang berbeda. Rating bintang dipakai sebagai metadata, bukan pengganti label sentimen aspek.

BOD: bahan tujuan dan ruang lingkup

Komponen	Rancangan
Tujuan	Mengukur kesesuaian label LLM dengan label manual; membandingkan model berlatih gold/silver; merangkum keluhan per aspek dan versi.
Objek dan unit	Ulasan SATUSEHAT Mobile. Satu ID ulasan memiliki enam kategori aspek, masing-masing dengan satu dari empat label.
Pertanyaan penelitian	RQ1: seberapa sesuai label LLM dan manual? RQ2: bagaimana kinerja model gold/silver? RQ3: bagaimana sentimen aspek berbeda antarversi?
Ruang lingkup	Aspect Category Sentiment Analysis (ACSA); label tidak_disebut, positif, negatif, netral. Ekstraksi triplet/quad opini di luar lingkup.
Keluaran	Dataset terdokumentasi, panduan anotasi, model pembanding, hasil evaluasi, serta analisis aspek per versi aplikasi.

Istilah dan format BOD belum dijelaskan pada deskripsi tugas. Bagian ini menyajikan bahan tujuan, ruang lingkup, serta rancangan penelitian; format akhirnya disesuaikan dengan arahan dosen. Konfirmasi dosen belum dinyatakan diperoleh.

Sumber: Rancangan topik dan metode week 10.

Sumber dan contoh dataset

Data diperoleh melalui scraping ulasan Google Play. Tidak menggunakan dataset Kaggle pada rancangan ini.

Item	Keterangan
Aplikasi	SATUSEHAT Mobile; package ID com.telkom.tracencare.
Sumber	Halaman SATUSEHAT Mobile di Google Play.
Pengambilan	google-play-scraper 1.2.7; bahasa id, negara id, urutan terbaru (Sort.NEWEST). Target 15.000 ulasan.
Berkas sumber	data/raw/com.telkom.tracencare_reviews.csv. Dataset mentah disimpan terpisah dari kode.

Struktur data: sembilan kolom

Kolom	Isi
reviewId	ID penghubung ulasan, anotasi, split, dan prediksi.
at; score; content	Tanggal ulasan, rating 1-5, dan teks ulasan.
thumbsUpCount	Jumlah penanda ulasan membantu.
reviewCreatedVersion; appVersion	Metadata versi aplikasi; nilai dapat kosong.
replyContent; repliedAt	Balasan pengembang dan waktunya; tidak menjadi input teks model.

Contoh data yang tercatat pada pilot

Teks ulasan	Ilustrasi interpretasi
baru coba login, langsung error dan force close	akun_login: negatif; performa: negatif.
Mudah operasionalnya, bagus untuk monitoring rekam medis	kemudahan_penggunaan: positif; fitur_kesehatan: positif.
belum di coba	umum: netral.

Contoh berasal dari dokumentasi pilot. Interpretasi di atas adalah ilustrasi pedoman, bukan label gold yang sudah disepakati. Nama dan foto pengguna tidak termasuk kolom dataset.

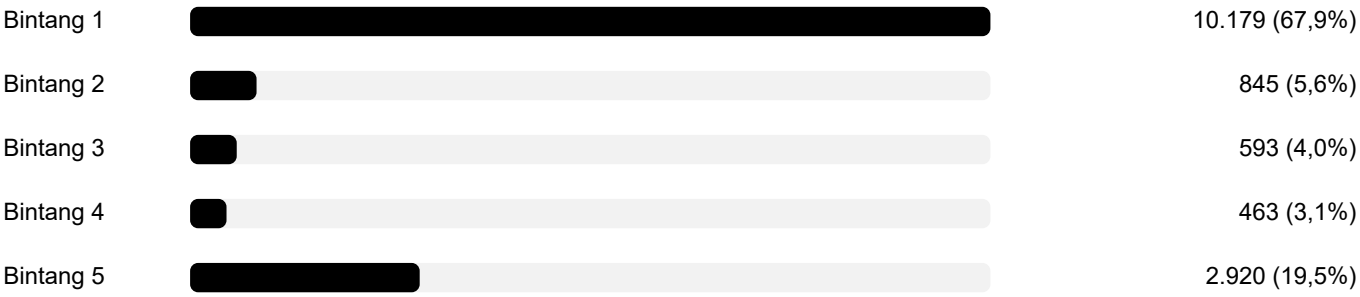
Sumber: Sumber, kolom, dan contoh ulasan pilot.

Karakteristik data

Ringkasan pilot yang tercatat pada 3 November 2026. Angka berikut berasal dari dokumentasi repo, bukan hasil scraping atau penghitungan ulang saat PDF dibuat.

Ukuran	Pilot 2.000 ulasan	Pilot 15.000 ulasan
Rentang tanggal	3 Des 2025 - 2 Nov 2026	17 Jul 2023 - 2 Nov 2026
Median kata	7	10
Minimal 3 kata	72,2%	83,3%
Minimal 8 kata	47,5%	59,7%
Duplikat persis	329	1.676
Versi terisi	79%	73,8%
Versi dengan >= 50 ulasan	9	54
Pool setelah filter/deduplikasi	Tidak dirangkum	12.297 (tercatat pada pilot)

Distribusi rating pada 15.000 ulasan mentah



- Sebanyak 67,9% data mentah memiliki rating 1. Distribusi ini tidak sama dengan distribusi pada pool setelah preprocessing.
- Versi yang kosong perlu dipisahkan dari analisis per versi. Data pendek dan duplikat perlu ditangani sebelum pembagian latih/uji.
- Teks informal serta negasi perlu dipertahankan maknanya. Rating bintang tidak otomatis menentukan sentimen setiap aspek.

Sumber: Statistik eksplorasi pilot dan batas penyimpanan.

Rancangan algoritma dan evaluasi

Algoritma berikut adalah rancangan eksperimen. PDF ini tidak menyatakan model telah dilatih atau memiliki skor pada data uji nyata.

Alur penelitian

Scraping → preprocessing → kalibrasi dan label manual → pelabelan silver oleh LLM → pelatihan model → evaluasi pada gold uji → analisis per versi.

Model pembanding

Kode	Algoritma	Data / pendekatan
B1	TF-IDF + Logistic Regression per aspek	400 ulasan gold latih; normalisasi slang khusus baseline.
B2	IndoBERTweet sentence-pair	Pasangan teks ulasan dan deskripsi aspek; gold latih.
B3	LLM langsung, few-shot	Contoh dari kalibrasi; tanpa pelatihan encoder.
P1	IndoBERTweet sentence-pair	Silver, yaitu label yang dihasilkan LLM.
P2	IndoBERTweet sentence-pair	Silver, kemudian dilanjutkan dengan gold latih.

Kategori dan pembagian data

Kategori awal: akun_login, registrasi_data, fitur_kesehatan, performa, kemudahan_penggunaan, dan umum. Empat label: tidak_disebut, positif, negatif, netral. Kategori dan pedoman ditinjau melalui kalibrasi.

Rancangan split: 50 ulasan kalibrasi; 800 gold yang terdiri dari 400 latih, 100 validasi, dan 300 uji; sisanya silver. Split dilakukan berdasarkan ID ulasan, dengan seed 42 dan stratifikasi rating. Gold tidak dimasukkan ke silver.

Ukuran evaluasi yang direncanakan

- F1 pasangan aspek-sentimen sebagai ukuran utama; F1 deteksi aspek dan macro-F1 sentimen per aspek sebagai rincian.
- Cohen's kappa untuk kesepakatan label; waktu inferensi per 1.000 ulasan untuk efisiensi.
- Pemilihan konfigurasi memakai validasi. Set uji disimpan untuk penilaian akhir; analisis per versi memakai versi dengan cukup ulasan.

Sumber: Keputusan metode, split, dan definisi metrik.