WEB MINING

WEEK 11: CODING PREPROCESSING DAN ANOTASI

ANALISIS SENTIMEN BERBASIS ASPEK ULASAN GOOGLE PLAY SATUSEHAT MOBILE



ANGGOTA TIM

Bambang Herlambang	5803024019
Efraim Melvyn Rafelino Lahai	5803024009
Jap Robertus Kurniawan Setiabudi	5803024004
Robertus Geraldyn Alexandro Gabeler	5803024025

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS KATOLIK WIDYA MANDALA

SURABAYA

2026

Coding awal dan progres implementasi

Laporan week 11: rancangan preprocessing, perangkat anotasi manusia, dan bukti pengujian kode. Cakupan coding tugas berlangsung selama week 11-12.

Cakupan laporan

Fondasi scraping/eksplorasi serta alat kalibrasi dan anotasi tersedia. Pipeline preprocessing penuh, pelabelan nyata, training, dan evaluasi model masih perlu dilanjutkan. Hasil tes kode tidak disamakan dengan hasil penelitian.

Komponen	Yang tersedia	Status
Pengambilan data	src/scrape_reviews.py; dokumentasi pilot 15.000 ulasan.	Kode tersedia; CSV belum tersedia di workspace laporan.
Eksplorasi	src/pilot_stats.py dan statistik pilot di data/README.md.	Statistik terdokumentasi; tidak dihitung ulang dalam PDF ini.
Preprocessing	Aturan, format text_llm/text_model, dan rancangan split.	Rancangan tersedia; pipeline penuh belum diimplementasikan.
Kalibrasi/anotasi	src/annotation.py; prepare, audit, finalize.	Kode tersedia; belum diterapkan pada dataset nyata.
Pengujian	8 tes perilaku dan uji alur CLI dengan data buatan; CI Python 3.14 berhasil.	Menguji perilaku alat, bukan validitas label manusia.
Mining/evaluasi model	B1-B3 dan P1-P2; definisi metrik.	Rancangan; model dan skor uji nyata belum tersedia.

Alur berkas

CSV mentah → reviews_clean.csv dan split.csv → lembar kalibrasi → pedoman yang disepakati → anotasi gold → audit/adjudikasi → gold.csv. Model dan evaluasi memakai versi label final yang sama.

Sumber: Status implementasi proyek.

Rancangan preprocessing

Aturan berikut mengikuti keputusan metode yang sudah terdokumentasi. Ini spesifikasi coding yang akan diterapkan, bukan klaim pipeline sudah selesai dijalankan.

Tahap	Aturan
Seleksi waktu	Keluarkan ulasan sebelum 1 Maret 2023.
Teks kosong/spasi	Buang teks kosong; rapikan spasi dan baris baru.
Panjang teks	Minimal tiga kata; catat jumlah data yang dikeluarkan.
Duplikasi	Untuk latih/evaluasi, deduplikasi setelah huruf kecil dan spasi dirapikan; simpan ulasan paling awal.
Penyamaran	NIK → [NIK], telepon → [TELEPON], email → [EMAIL], URL → HTTPURL.
text_llm	Pertahankan huruf besar, tanda baca, dan emoji.
text_model	Huruf kecil; emoji menjadi teks Indonesia; pengulangan huruf >= 3 kali menjadi dua.
Negasi dan bentuk kata	Tanpa stopword removal dan tanpa stemming.
Slang	Normalisasi slang hanya untuk B1 (TF-IDF); tidak dipaksakan pada encoder/LLM.
Bahasa dan balasan	Tidak memakai filter bahasa; balasan pengembang tidak menjadi masukan.
Analisis versi	Pertahankan duplikat untuk analisis versi; aturan waktu, kosong, panjang, dan penyamaran tetap berlaku.

Kontrak keluaran

reviews_clean.csv: reviewId, at, score, reviewCreatedVersion, text_llm, text_model, n_words, in_pool. split.csv: reviewId, split. Satu ID hanya berada pada satu split.

Seed dan hash sumber dicatat agar hasil dapat ditelusuri. Vocabulary/TF-IDF dilatih hanya pada data latih; data validasi/uji memakai transformasi yang sudah dipelajari.

Sumber: Aturan preprocessing dan format berkas.

Implementasi kalibrasi dan anotasi

Kode tersedia di src/annotation.py. Seluruh label pada lembar awal kosong dan diisi berdasarkan pembacaan manusia.

Perintah	Perilaku yang diterapkan
prepare	Memeriksa ID/split dan ukuran data; membuat lembar kalibrasi serta gold. Tidak mengambil sampel ulang atau mengubah split sumber.
audit	Memeriksa label dan kecocokan teks/ID; menghitung kesepakatan/kappa sebelum adjudikasi; membuat daftar sel berbeda.
finalize	Menolak perbedaan yang belum diputuskan; memeriksa adjudicator pihak ketiga pada set uji; mengekspor label tanpa teks ulasan.

Struktur penugasan dan pencegahan kebocoran

Tahap	Jumlah dan aturan
Kalibrasi	50 ulasan yang sama untuk empat anotator; terpisah dari gold/silver.
Gold	800 ulasan unik. Latih 400 dan validasi 100 dilabeli sekali; 300 uji dilabeli dua kali.
Beban default	1.100 penugasan gold, yaitu 275 per anotator; ditambah 50 ulasan kalibrasi per anotator.
Tampilan lembar	Hanya ID, kode anotator, teks, enam aspek, dan catatan. Rating dan prediksi LLM tidak ditampilkan.
Berkas akhir	gold.csv, label awal tanpa teks, provenance.csv, dan report.json dengan hash input serta kesepakatan sebelum adjudikasi.

Pemeriksaan yang membatasi kesalahan

Label kosong/di luar empat pilihan ditolak. Aspek umum tidak boleh bersamaan dengan aspek khusus. Perubahan teks/ID, ID hilang, keputusan audit kedaluwarsa, dan penimpaan folder hasil juga ditolak.

Jika satu aspek hanya memiliki satu kelas yang sama pada kedua anotator, kappa tidak terdefinisi: JSON null, bukan nol. Perbedaan semantik dibahas kelompok; kode tidak mengklaim memahami makna ulasan.

Sumber: Kode prepare, audit, dan finalize.

Cara menjalankan dan bukti uji

Jalankan dari akar repository setelah reviews_clean.csv dan split.csv versi yang disepakati tersedia. Contoh multiline di bawah menggunakan PowerShell.

1. Menyiapkan lembar kosong

```
$reviewsFile = 'data/processed/reviews_clean.csv'
$splitFile = 'data/annotations/split.csv'
python src/annotation.py prepare --reviews $reviewsFile --split $splitFile
```

2. Audit sesudah empat lembar kalibrasi lengkap

```
python src/annotation.py audit --phase kalibrasi `
  --output data/annotation_workspace/audit_kalibrasi_v1
```

Bahas perbedaan di resolutions.csv, isi label akhir, adjudicator, dan alasan. Perbarui pedoman sesuai hasil diskusi. Untuk fase gold, pakai --phase gold; perbedaan set uji diputuskan anotator ketiga.

3. Contoh ekspor gold setelah adjudikasi

```
python src/annotation.py finalize --phase gold `
  --resolutions data/annotation_workspace/audit_gold_v1/resolutions.csv `
  --output data/annotations/final_v1
```

Bukti pemeriksaan implementasi

Delapan tes memakai 850 ulasan buatan: keseimbangan penugasan, reproduksibilitas, validasi split/ID, penolakan label kosong, kecocokan teks dan identitas, adjudikasi pihak ketiga, audit kedaluwarsa, serta kasus kappa yang dapat dihitung manual. Uji CLI prepare → audit → finalize juga berhasil pada data buatan.

CI Python 3.14: run 41646000734 berhasil. Kode dan bukti versi: commit 3355814.

Yang masih diperlukan: dataset/split nyata, kalibrasi manusia, label gold, implementasi preprocessing penuh, model, dan evaluasi nyata. Tidak ada skor model atau kappa kelompok yang dibuat-buat.

Sumber: Panduan anotasi dan penyimpanan berkas.